

Mario David De León - 19019
Javier Sebastián Valle - 20159

Feed Forward NN (Red Simple)

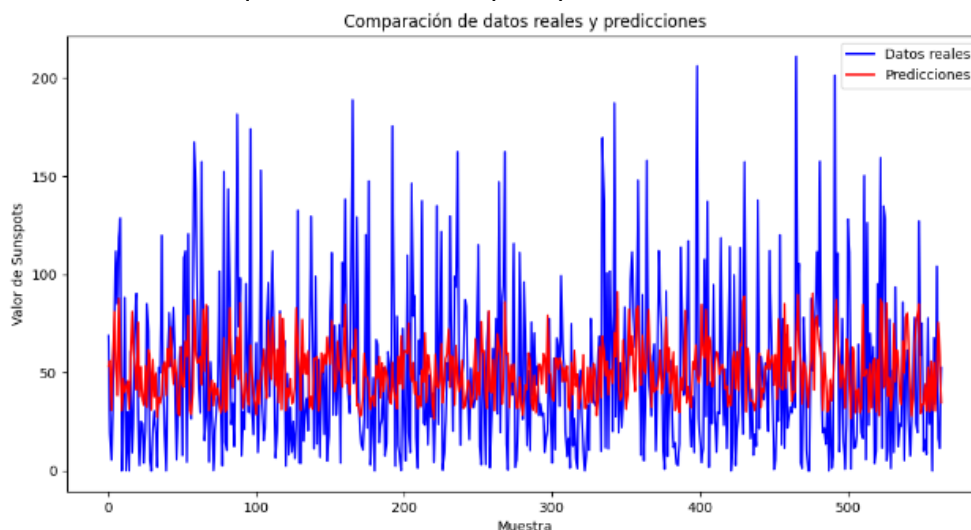
Resultados y discusión:

MSE: 1722.9759370342256
RMSE: 41.5087453078773
MAE: 33.23325906983504


La métrica de MSE mide el promedio de los cuadrados de errores. Se puede ver que es un MSE bastante alto, de 1722.9759. Esto indica que, en promedio, los cuadrados de los errores entre las predicciones y los valores verdaderos son de dicha magnitud. Dado que el error está elevado al cuadrado, es un poco más difícil de interpretar que las otras dos métricas. RMSE es la raíz cuadrada de MSE. El valor alto puede deberse a una gran variabilidad o valores atípicos muy significativos.

Sin embargo, el MAE es el promedio de los valores absolutos entre valores reales y predicciones. Esto significa que, en promedio, las predicciones se desvían del valor real en aproximadamente 33.23 unidades. Esto es significativo y muestra que el modelo no está capturando de manera correcta toda la variabilidad de los datos. Es posible que la arquitectura del modelo no sea lo suficientemente compleja, como su nombre lo indica, red simple. También puede deberse a que los hiper parámetros no están optimizados.

Podemos ver la dificultad que tuvo el modelo para predecir datos:



Ahora bien, la siguiente gráfica muestra las pérdidas del entrenamiento y las de validación:



Podemos ver que la pérdida de entrenamiento disminuye. Esto significa que el modelo está mejorando para adaptarse a los datos de entrenamiento. Esto es lo que se esperaría para determinar si el modelo está recibiendo el entrenamiento adecuado.

A pesar de ello, si la pérdida de validación no está disminuyendo y hay picos significativos, es posible que el modelo no esté generalizando adecuadamente a los datos que nunca ha visto. Los picos pronunciados pueden ser el resultado de problemas con la optimización del modelo o variabilidad en los datos de validación.

La gráfica sugiere que el modelo aprende algo de los datos de entrenamiento, pero no lo hace bien al generalizar a los datos de validación. Esta conducta podría indicar un sobreajuste.

RNN

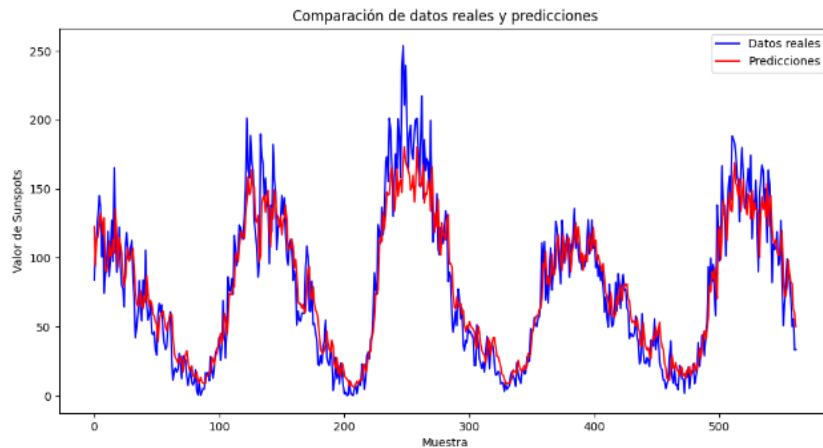
Resultados y discusión:

MSE: 402.66540713866675
 RMSE: 20.066524540604103
 MAE: 14.840964640417132

El error cuadrático medio es de 402.67, mucho menor que el del modelo Feed Forward. Esto significa que, en general, las predicciones del modelo RNN están más cerca de los valores reales que las del modelo anterior. En comparación con el modelo Feed Forward (41.51), la raíz del error cuadrático medio es de 20.07.


El error absoluto medio es de 14.84, más bajo que el del modelo Feed Forward. Esto indica que, incluso si los errores no se elevan al cuadrado (como en el MSE), las predicciones del modelo RNN están más cerca de los valores reales que las del modelo anterior. El modelo RNN tiene un desempeño mucho mejor que el Feed Forward en la predicción de sunspots. Esto tiene sentido porque las RNN están diseñadas para tratar con datos de series temporales y pueden capturar patrones a lo largo del tiempo.

Las redes neuronales recurrentes son adecuadas para tareas que involucran datos de series temporales. La gráfica muestra que el modelo RNN aprendió a predecir los datos de sunspots de manera efectiva:



Solo hay que asegurar que no haya sobreajuste en el modelo. Para evitar eso se puede reducir la complejidad del modelo o agregar regularización.

La siguiente gráfica muestra las pérdidas del entrenamiento y las de validación:




Ahora se observa un gran problema de este modelo. Se nota que la "train loss" disminuye constantemente mientras que la "val loss" tiene picos altos y muestra una tendencia ascendente. Esto podría ser un signo de overfitting. Puede que el modelo esté aprendiendo patrones específicos de datos de entrenamiento que no se aplican necesariamente a los datos de validación. Para abordar el problema se puede aplicar regularización, reducir la complejidad del modelo, y hasta generar datos sintéticos para poder seguir entrenando al modelo. También se puede parar el entrenamiento temprano antes de que ocurra el overfitting.

LSTM

MSE: 1732.226342874984
 RMSE: 41.62002334063478
 MAE: 33.5877518511833


Estos valores son similares a los del modelo anterior (Feed Forward), lo que indica que ambos modelos están obteniendo resultados de precisión similares. Sin embargo, el

MAE y RMSE para el modelo LSTM son ligeramente más altos, lo que indica que el modelo Feed Forward podría estar mejor ajustado.



Aunque no se ajustan perfectamente, las predicciones siguen la tendencia de los datos reales, como se muestra en la gráfica. Las predicciones sólo capturan una pequeña parte del rango de valores observados en los datos reales. Esto demuestra que el modelo no está recopilando toda la variabilidad de los datos.

La siguiente gráfica muestra las pérdidas del entrenamiento y las de validación:



La pérdida de entrenamiento disminuye con el tiempo, como sucede con otros modelos, lo que indica que el modelo está aprendiendo. Sin embargo, la pérdida de validación no disminuye en general y tiene picos pronunciados, lo que indica que el modelo no se está generalizando bien a los datos de validación.

Arquitecturas, y cuál usar al final

Ventajas y desventajas de cada una

<u>Feed Forward Neural Network (Red Simple)</u>	<u>Recurrent Neural Network (RNN)</u>	<u>Long Short-Term Memory (LSTM)</u>
<ul style="list-style-type: none">• Ventajas: Es sencilla de implementar y puede ser suficiente para patrones que no requieran memoria a largo plazo.• Desventajas: No tiene en cuenta la secuencia de los datos y trata cada entrada independientemente. Esto puede ser un problema para las series temporales donde la secuencia y el contexto temporal son importantes.	<ul style="list-style-type: none">• Ventajas: Tiene en cuenta la secuencia de los datos y puede capturar patrones temporales en la serie de tiempo.• Desventajas: Los RNN tradicionales tienden a sufrir problemas con gradientes que se desvanecen o explotan, lo que hace que sea difícil capturar patrones a largo plazo.	<ul style="list-style-type: none">• Ventajas: Al igual que los RNN, tiene en cuenta la secuencia de los datos, pero además, los LSTMs están diseñados para capturar patrones a largo plazo en la serie de tiempo.• Desventajas: Son más complejas y costosas en términos computacionales que las RNN tradicionales y las Feed Forward NN.

¿Cuál usar?

Recurrent Neural Network (RNN)

Se observó que la RNN superaba a los otros modelos en varias áreas cuando se compararon los modelos de red neuronal Feed Forward, RNN y LSTM para predecir la cantidad de sunspots. Las métricas de rendimiento más bajas de la RNN, como el error absoluto medio (MAE), el error cuadrático medio raíz (RMSE) y el error cuadrático medio (MSE), indican predicciones más precisas en promedio.

Además, mientras que los otros modelos tenían predicciones con un rango más limitado, la RNN demostró un ajuste más cercano a la tendencia de los datos reales en la comparación visual de las predicciones con los datos reales. A pesar de que todos los modelos presentaron problemas de generalización, la RNN demostró una tendencia de pérdida más consistente y estable.

Las RNN están teóricamente diseñadas para capturar patrones temporales y manejar secuencias de datos. Como resultado, son ideales para predecir series temporales como la cantidad de sunspots. Por lo tanto, basándose tanto en la teoría como en el rendimiento observado, la RNN parece ser la opción más adecuada para este caso. Sin embargo, aún hay espacio para mejorar su rendimiento.